THAI BUSINESS REPORTS / EXAMINATION PROJECT

AI-Driven OCR and Web Scraping System for Business Insight Analysis

ระบบ AI สำหรับ OCR และ Web Scraping เพื่อวิเคราะห์ข้อมูลเชิงลึกทางธุรกิจ

นายจักรภัทร พนมวัฒนศักดิ์
66070026 | 66070026@kmitl.ac.th

นายวชิรวิทย์ ธนีสันต์
66070176 | 66070176@kmitl.ac.th

อาจารย์ที่ปรึกษา ดร.ณัฏฐ์ ดิลกธนากุล

The question

Can structured table access and tool routing improve source-bound answers over one-pass dense retrieval on the same Thai annual reports?

One corpus. Two measured systems.

Collect
Official PDFs
URLs and hashes

→

Extract
OCR and tables
Local stored corpus

→

Retrieve
S0 dense search
S1 routing + SQL

→

Inspect
Answer tuples
Original PDF citations

Final frozen run

4 reports · 1,431 / 1,447 pages indexed · 6,928 searchable chunks
498 answerable questions + 32 controls per system | 1,060 first outcomes

	S0 Dense RAG	S1 Full App
Strict complete answers	15.86% (79/498)	12.05% (60/498)
Numerical relations	33.43% (119/356)	29.78% (106/356)
Control abstention	75.00% (24/32)	87.50% (28/32)
Response time p50 / p95	7.19 / 19.90 s	13.01 / 35.55 s

Measured conclusion

Full App did not outperform Dense RAG on strict completion or numerical relations.
It abstained more appropriately on controls and took longer to answer.

Why source context matters

TISCO Bank cash: 818,057 thousand baht on PDF page 128; rounded 818 million on page 266. Entity, year, scale and requested precision must stay attached.

Evidence limits

1,060 / 1,060 AI-assisted assessments complete; no independent human confirmation.
34 consistency adjudications; 3 defective source labels disclosed with paired sensitivity.
Quality goal >80% remains unmet. Strict scores are not certified benchmark accuracy.

Cost transparency

Known uncached Gemini token components: ingestion $3.44; S0 queries $4.07; S1 $5.61.
These are partial estimates, not invoices. Missing usage, thinking, cache and other costs remain unknown.

คณะเทคโนโลยีสารสนเทศ | สาขาเทคโนโลยีปัญญาประดิษฐ์
สถาบันเทคโนโลยีพระจอมเกล้าเจ้าคุณทหารลาดกระบัง | ภาคการศึกษาที่ 2 ปีการศึกษา 2568

Sources: KCE, OSP, HMPRO and TISCO Bank One Reports 2025; frozen result manifest and source QA.